数值实验框架：LAD、弹性网络正则化与全变分图像去噪

说明与统一记号

本文档在已整理的 Markdown 文档基础上，进一步面向数值实验复现，整理三个测试问题：

(1) LAD 稀疏恢复；

(2) 弹性网络正则化；

(3) 全变分图像去噪。

每个问题分别给出可测试的算法：GrpADMM、AGrpADMM、双子问题非精确准则 IADMM、PADMC、APADMC 的算法参数、算法框架和子问题显式解。对比原则为：一般凸实验只比较一般算法，强凸实验才加入加速算法。若某个算法的加速条件要求强凸性，而当前模型本身不强凸，则本文明确标注其只适用于强凸变体，不纳入基础一般凸实验的默认对比。

本文使用如下两个近端算子。

Soft-thresholding 算子 对标量或向量逐分量定义

$$\mathcal{S}_\kappa(z) = \operatorname{sign}(z)\max\{|z| - \kappa, 0\}.$$

因此

$$\arg\min_x \left\{\lambda \|x\|_1 + \frac{a}{2}\|x - v\|^2\right\} = \mathcal{S}_{\lambda/a}(v), \qquad a > 0.$$

二维向量组 shrinkage 算子 对每个像素对应的二维向量 $z_i \in \mathbb{R}^2$，定义

$$\mathcal{G}_\kappa(z_i) = \max\left\{1 - \frac{\kappa}{\|z_i\|_2}, 0\right\} z_i,$$

并约定 $z_i = 0$ 时 $\mathcal{G}_\kappa(0) = 0$。因此

$$\arg\min_{w_i \in \mathbb{R}^2} \left\{\|w_i\|_2 + \frac{a}{2}\|w_i - v_i\|_2^2\right\} = \mathcal{G}_{1/a}(v_i).$$

增广拉格朗日符号 GrpADMM、AGrpADMM、PADMC、APADMC 统一使用

$$\mathcal{L}_\sigma(x,w,\lambda)=p(x)+q(w)+\langle\lambda,Hx-w\rangle+\frac{\sigma}{2}\|Hx-w\|^2.$$

IADMM 文献使用相反的乘子符号:

$$\widehat{\mathcal{L}}_\beta(x,w;\lambda)=p(x)+q(w)-\langle\lambda,Hx-w\rangle+\frac{\beta}{2}\|Hx-w\|^2.$$

两种写法等价，只需注意乘子更新方向相反。

1 LAD 稀疏恢复实验

1.1 实验模型与数据生成

LAD 稀疏恢复模型为

$$\min_x \ \mu \|x\|_1 + \|Kx - c\|_1 .$$

引入辅助变量 $w = Kx$，得到二块约束模型

$$\min_{x,w} \{\mu \|x\|_1 + \|w - c\|_1 \mid Kx - w = 0\} .$$

本节令

$$p(x) = \mu \|x\|_1 , \qquad q(w) = \|w - c\|_1 , \qquad H = K.$$

建议测试数据按如下方式生成：

1. 生成 $K \in \mathbb{R}^{p\times q}$，元素独立服从 $N(0,1)$。
2. 生成 s-稀疏真值 $x^\natural$，非零位置均匀随机，非零值由 `randn` 生成。
3. 令 $Kx^\natural$ 中随机 5% 的分量被替换为 $\left\|Kx^\natural\right\|_\infty$ 或 $-\left\|Kx^\natural\right\|_\infty$，概率各为 0.5，得到 c。
4. 推荐参数：$\mu = 0.05$，初值 $(x^0, w^0, \lambda^0) = (0, 0, -c)$。

评价指标可取

$$\frac{|\Phi(x^k, w^k) - \Phi^*|}{|\Phi^*|}, \qquad \left\|Kx^k - w^k\right\| , \qquad \text{CPU time.}$$

1.2 GrpADMM

参数

文献中的 LAD 实验采用

$$S = I, \qquad T = 0, \qquad \sigma = 1, \qquad \psi \in \{1.1, 1.3, 1.618\},$$

并取

$$\tau = \frac{\psi}{\sigma \|K\|^2}.$$

通常先比较不同 ψ，随后固定 $\psi = 1.618$。

算法框架

令 $u^0 = x^0$。第 n 次迭代：

$$u^n = \frac{\psi - 1}{\psi} x^{n-1} + \frac{1}{\psi} u^{n-1},$$

$$x^n = \arg\min_x \left\{ p(x) + \left\langle \lambda^{n-1}, Kx - w^{n-1} \right\rangle + \frac{1}{2\tau} \left\| x - u^n \right\|_S^2 \right\},$$

$$w^n = \arg\min_w \left\{ q(w) + \left\langle \lambda^{n-1}, Kx^n - w \right\rangle + \frac{\sigma}{2} \left\| Kx^n - w \right\|^2 + \frac{1}{2} \left\| w - w^{n-1} \right\|_T^2 \right\},$$

$$\lambda^n = \lambda^{n-1} + \sigma(Kx^n - w^n).$$

子问题显式解

当 $S = I, T = 0$ 时，

$$x^n = \mathcal{S}_{\tau\mu} \left(u^n - \tau K^\top \lambda^{n-1} \right),$$

$$w^n = c + \mathcal{S}_{1/\sigma} \left(Kx^n + \frac{\lambda^{n-1}}{\sigma} - c \right).$$

1.3 AGrpADMM

基础 LAD 模型中的 $p(x) = \mu \left\| x \right\|_1$ 不强凸，因此基础 LAD 数值实验不默认比较 AGrpADMM。AGrpADMM 仅适用于加入二次强凸项后的 LAD 型弹性网络变体：

$$\min_{x,w} \left\{ \mu_1 \left\| x \right\|_1 + \mu_2 \left\| x \right\|^2 + \left\| w - c \right\|_1 \,\middle|\, Kx - w = 0 \right\}.$$

该模型也可作为第二节弹性网络实验的一种 LAD 型版本。

参数

建议沿用文献设置：

$$\mu_1 = 0.05, \qquad \mu_2 = 0.04, \qquad \rho = 0.001, \qquad S = \mu_2 I, \qquad T = 0.01 I,$$

$$\psi = 1.618, \qquad \sigma_0 = \rho, \qquad \tau_0 = \frac{\psi \lambda_{\min}(S)}{\sigma_0 \left\| K \right\|^2}.$$

算法框架

令 $u^0 = x^0, t_0 = 1$。第 n 次迭代：

$$u^n = \frac{\psi - 1}{\psi} x^{n-1} + \frac{1}{\psi} u^{n-1},$$

$$x^n = \arg\min_x \left\{ \mu_1 \left\| x \right\|_1 + \mu_2 \left\| x \right\|^2 + \left\langle \lambda^{n-1}, Kx - w^{n-1} \right\rangle + \frac{1}{2\tau_{n-1}} \left\| x - u^n \right\|_S^2 \right\},$$

$$w^n = \arg\min_w \left\{ \|w-c\|_1 + \left\langle \lambda^{n-1}, Kx^n - w \right\rangle + \frac{\sigma_{n-1}}{2}\|Kx^n - w\|^2 + \frac{1}{2t_{n-1}}\left\|w - w^{n-1}\right\|_T^2 \right\},$$

$$\lambda^n = \lambda^{n-1} + \sigma_{n-1}(Kx^n - w^n),$$

$$t_n = \frac{1+\sqrt{1+4t_{n-1}^2}}{2}, \qquad \sigma_n = \rho t_n, \qquad \tau_n = \frac{\psi\lambda_{\min}(S)}{\sigma_n\|K\|^2}.$$

子问题显式解

若 $S = s_x I$，则令

$$r_x = \frac{s_x}{\tau_{n-1}}, \qquad v_x = u^n - \frac{1}{r_x}K^\top\lambda^{n-1}.$$

则

$$x^n = \mathcal{S}_{\mu_1/(r_x+2\mu_2)}\left(\frac{r_x}{r_x+2\mu_2}v_x\right).$$

若 $T = t_w I$，令

$$a_w = \sigma_{n-1} + \frac{t_w}{t_{n-1}}, \qquad v_w = \frac{\sigma_{n-1}Kx^n + \lambda^{n-1} + (t_w/t_{n-1})w^{n-1}}{a_w}.$$

则

$$w^n = c + \mathcal{S}_{1/a_w}(v_w - c).$$

1.4 双子问题非精确准则 IADMM

参数

使用 IADMM 的双子问题非精确准则：

$$\beta > 0, \qquad \tau \in (0,1], \qquad \sigma_1,\sigma_2 \geq 0, \qquad \sigma_1+\sigma_2 < 1, \qquad \sigma_3 \in [0,1).$$

算法框架

采用 IADMM 符号

$$\widehat{\mathcal{L}}_\beta(x,w;\lambda) = p(x) + q(w) - \langle\lambda, Kx-w\rangle + \frac{\beta}{2}\|Kx-w\|^2.$$

第 k 次迭代中，近似求解

$$x^{k+1} \approx \arg\min_x \widehat{\mathcal{L}}_\beta(x, w^k; \lambda^k),$$

$$w^{k+1} \approx \arg\min_w \widehat{\mathcal{L}}_\beta(x^{k+1}, w; \lambda^k).$$

误差向量取

$$d_1^{k+1} \in \partial p(x^{k+1}) - K^\top\left[\lambda^k - \beta(Kx^{k+1} - w^k)\right],$$

$$d_2^{k+1} \in \partial q(w^{k+1}) + \lambda^k - \beta(Kx^{k+1} - w^{k+1}).$$

要求

$$\frac{2}{\beta}\left|\left\langle z_1^k - x^{k+1}, d_1^{k+1}\right\rangle\right| + \tau\left\|d_1^{k+1}\right\|^2 \le \sigma_1\left\|Kx^{k+1} - w^k\right\|^2,$$

$$\frac{2}{\beta}\left|\left\langle z_2^k - w^{k+1}, d_2^{k+1}\right\rangle\right| + \tau\left\|d_2^{k+1}\right\|^2 \le \sigma_2\left\|Kx^{k+1} - w^k\right\|^2 + \sigma_3(1-\tau)\left\|Kx^{k+1} - w^{k+1}\right\|^2.$$

更新

$$\lambda^{k+1} = \lambda^k - \tau\beta(Kx^{k+1} - w^{k+1}),$$

$$z_1^{k+1} = z_1^k - \tau\beta d_1^{k+1}, \qquad z_2^{k+1} = z_2^k - \tau\beta d_2^{k+1}.$$

子问题显式解与可计算近似

LAD 的 x-子问题是

$$\min_x \ \mu\|x\|_1 - \left\langle \lambda^k, Kx - w^k\right\rangle + \frac{\beta}{2}\left\|Kx - w^k\right\|^2,$$

一般没有逐分量闭式解，可用 CG、FISTA 或近端梯度内层迭代，直到满足上面的相对误差准则。若使用一次线性化近端步，取 $\rho_x > \beta\|K\|^2$，则可用

$$v_x = x^k - \frac{1}{\rho_x}K^\top\left[\beta(Kx^k - w^k) - \lambda^k\right], \qquad x^{k+1} \approx \mathcal{S}_{\mu/\rho_x}(v_x).$$

w-子问题有闭式解：

$$w^{k+1} = c + \mathcal{S}_{1/\beta}\left(Kx^{k+1} - \frac{\lambda^k}{\beta} - c\right).$$

1.5 PADMC

参数

可选线性化近端参数

$$S_x = r_x I - \beta K^\top K, \qquad r_x > \beta\|K\|^2, \qquad S_w = s_w I, \quad s_w \ge 0,$$

以及凸组合参数

$$\alpha_x, \alpha_w \in (0, 2].$$

若要退化为 PADMM，可取 $\alpha_x = \alpha_w = 1$。

算法框架

令 $\bar{x}^0 = x^0, \bar{w}^0 = w^0$。第 k 次迭代：

$$\bar{x}^{k+1} = \alpha_x x^k + (1-\alpha_x)\bar{x}^k, \qquad \bar{w}^{k+1} = \alpha_w w^k + (1-\alpha_w)\bar{w}^k,$$

$$x^{k+1} = \arg\min_x \left\{ p(x) + \left\langle \lambda^k, Kx - w^k \right\rangle + \frac{\beta}{2} \left\| Kx - w^k \right\|^2 + \frac{1}{2} \left\| x - \bar{x}^{k+1} \right\|_{S_x}^2 \right\},$$
$$w^{k+1} = \arg\min_w \left\{ q(w) + \left\langle \lambda^k, Kx^{k+1} - w \right\rangle + \frac{\beta}{2} \left\| Kx^{k+1} - w \right\|^2 + \frac{1}{2} \left\| w - \bar{w}^{k+1} \right\|_{S_w}^2 \right\},$$
$$\lambda^{k+1} = \lambda^k + \beta(Kx^{k+1} - w^{k+1}).$$

子问题显式解

令

$$v_x = \bar{x}^{k+1} - \frac{1}{r_x} K^\top \left[\lambda^k + \beta(K\bar{x}^{k+1} - w^k) \right].$$

则

$$x^{k+1} = \mathcal{S}_{\mu/r_x}(v_x).$$

若 $S_w = s_w I$，令

$$a_w = \beta + s_w, \qquad v_w = \frac{\beta K x^{k+1} + \lambda^k + s_w \bar{w}^{k+1}}{a_w}.$$

则

$$w^{k+1} = c + \mathcal{S}_{1/a_w}(v_w - c).$$

1.6 APADMC

基础 LAD 不强凸，因此 APADMC 不作为基础 LAD 一般凸实验的默认对比算法。若使用 LAD 型弹性网络变体

$$p(x) = \mu_1 \|x\|_1 + \mu_2 \|x\|^2, \qquad q(w) = \|w - c\|_1,$$

则可将其作为强凸模型测试。固定 $\alpha_w = 1$，比较 $\alpha_x = 1, 2$。

APADMC 的框架与 PADMC 相同，但使用

$$\beta_k = \frac{2\mu_2(k+1)}{3\|K\|^2}$$

和缩放近端矩阵 $S_x/\beta_k, S_w/\beta_k$。若 $S_x = s_x I, S_w = s_w I$，则

$$a_x = \beta_k + \frac{s_x}{\beta_k}, \qquad v_x = \frac{\beta_k w^k - \lambda^k + (s_x/\beta_k)\bar{x}^{k+1}}{a_x} \quad \text{仅适用于约束} x - w = 0.$$

对于 LAD 约束 $Kx - w = 0$，若仍使用 $S_x = r_x I - \beta_k K^\top K$ 的线性化形式，则

$$r_{x,k} = \frac{r_x}{\beta_k}, \qquad v_x = \bar{x}^{k+1} - \frac{1}{r_{x,k}} K^\top \left[\lambda^k + \beta_k(K\bar{x}^{k+1} - w^k) \right],$$
$$x^{k+1} = \mathcal{S}_{\mu_1/(r_{x,k}+2\mu_2)} \left(\frac{r_{x,k}}{r_{x,k} + 2\mu_2} v_x \right),$$
$$a_w = \beta_k + \frac{s_w}{\beta_k}, \qquad v_w = \frac{\beta_k K x^{k+1} + \lambda^k + (s_w/\beta_k)\bar{w}^{k+1}}{a_w},$$
$$w^{k+1} = c + \mathcal{S}_{1/a_w}(v_w - c).$$

2 弹性网络正则化实验

2.1 实验模型与数据生成

采用 PADMC 文献中的 elastic-net 模型：

$$\min_x \ \eta \|x\|_1 + \gamma \|x\|^2 + \frac{1}{2}\|Ax-b\|^2 .$$

引入变量 y，写成

$$\min_{x,y} \left\{ \eta \|x\|_1 + \gamma \|y\|^2 + \frac{1}{2}\|Ay-b\|^2 \,\middle|\, x-y=0 \right\}.$$

令

$$p(x) = \eta \|x\|_1 , \qquad q(y) = \gamma \|y\|^2 + \frac{1}{2}\|Ay-b\|^2 .$$

其中 q 为 2γ-强凸函数。

建议数据：

1. 使用 Walsh–Hadamard 矩阵生成 A，随机抽取部分行并归一化，使 $AA^\top = I$。
2. 生成 s-稀疏真值 $x^\star$，观测 $b = Ax^\star + \omega$。
3. 推荐参数：$(q,n,s) = (2000, 8192, 1500)$，$\eta = 0.01$，$\gamma = 0.005$。
4. 初值 $(x^0, y^0, \lambda^0) = (0,0,0)$。

2.2 PADMC

参数

取

$$S_x = s_x I, \qquad S_y = s_y I, \qquad s_x = 100, \quad s_y = 50,$$
$$\alpha_y = 1, \qquad \alpha_x \in \{1, 2\}.$$

$\alpha_x = 1$ 对应 PADMM，$\alpha_x = 2$ 对应 PADMC。

算法框架

$$\bar{x}^{k+1} = \alpha_x x^k + (1-\alpha_x)\bar{x}^k, \qquad \bar{y}^{k+1} = \alpha_y y^k + (1-\alpha_y)\bar{y}^k,$$

$$x^{k+1} = \arg\min_x \left\{ \eta \|x\|_1 + \langle \lambda^k, x - y^k \rangle + \frac{\beta}{2}\left\|x-y^k\right\|^2 + \frac{s_x}{2}\left\|x-\bar{x}^{k+1}\right\|^2 \right\},$$

$$y^{k+1} = \arg\min_y \left\{ \gamma \|y\|^2 + \frac{1}{2}\|Ay-b\|^2 + \langle \lambda^k, x^{k+1} - y \rangle + \frac{\beta}{2}\left\|x^{k+1}-y\right\|^2 + \frac{s_y}{2}\left\|y-\bar{y}^{k+1}\right\|^2 \right\},$$

$$\lambda^{k+1} = \lambda^k + \beta(x^{k+1} - y^{k+1}).$$

子问题显式解

令

$$a_x = \beta + s_x, \qquad v_x = \frac{\beta y^k - \lambda^k + s_x \bar{x}^{k+1}}{a_x}.$$

则

$$x^{k+1} = \mathcal{S}_{\eta/a_x}(v_x).$$

令

$$M_y = A^\top A + (\beta + s_y + 2\gamma)I,$$

则

$$y^{k+1} = M_y^{-1}\left(A^\top b + \lambda^k + \beta x^{k+1} + s_y \bar{y}^{k+1}\right).$$

若 $AA^\top = I$，可用

$$(aI + A^\top A)^{-1} = \frac{1}{a}\left(I - \frac{A^\top A}{a+1}\right), \qquad a = \beta + s_y + 2\gamma,$$

快速计算 y-子问题。

2.3 APADMC

参数

由于 $q(y)$ 为 2γ-强凸，APADMC 可直接使用。令

$$\mu_q = 2\gamma, \qquad \beta_k = \frac{\mu_q(k+1)}{3\|B\|^2}.$$

在约束 $x - y = 0$ 中 $B = -I$，因此 $\|B\| = 1$，

$$\beta_k = \frac{2\gamma(k+1)}{3}.$$

仍取

$$S_x = s_x I, \quad S_y = s_y I, \quad s_x = 100, \quad s_y = 50, \quad \alpha_y = 1, \quad \alpha_x \in \{1, 2\}.$$

算法框架

APADMC 与 PADMC 结构相同，只是固定 β 替换为 β_k，近端项替换为

$$\frac{1}{2\beta_k}\left\|x - \bar{x}^{k+1}\right\|_{S_x}^2, \qquad \frac{1}{2\beta_k}\left\|y - \bar{y}^{k+1}\right\|_{S_y}^2.$$

乘子更新为

$$\lambda^{k+1} = \lambda^k + \beta_k(x^{k+1} - y^{k+1}).$$

子问题显式解

令

$$a_{x,k} = \beta_k + \frac{s_x}{\beta_k}, \qquad v_{x,k} = \frac{\beta_k y^k - \lambda^k + (s_x/\beta_k)\bar{x}^{k+1}}{a_{x,k}},$$

则

$$x^{k+1} = \mathcal{S}_{\eta/a_{x,k}}(v_{x,k}).$$

令

$$M_{y,k} = A^\top A + \left(\beta_k + \frac{s_y}{\beta_k} + 2\gamma\right) I.$$

则

$$y^{k+1} = M_{y,k}^{-1}\left(A^\top b + \lambda^k + \beta_k x^{k+1} + \frac{s_y}{\beta_k}\bar{y}^{k+1}\right).$$

若 $AA^\top = I$，仍可用 Sherman–Morrison–Woodbury 形式快速求解。

2.4　双子问题非精确准则 IADMM

参数

$$\beta > 0, \quad \tau \in (0,1], \quad \sigma_1, \sigma_2 \geq 0, \quad \sigma_1 + \sigma_2 < 1, \quad \sigma_3 \in [0,1).$$

算法框架

使用 IADMM 符号

$$\widehat{\mathcal{L}}_\beta(x, y; \lambda) = p(x) + q(y) - \langle \lambda, x - y\rangle + \frac{\beta}{2}\|x - y\|^2.$$

近似求解两个子问题，并检查

$$d_1^{k+1} \in \partial p(x^{k+1}) - \left[\lambda^k - \beta(x^{k+1} - y^k)\right],$$

$$d_2^{k+1} \in \partial q(y^{k+1}) + \lambda^k - \beta(x^{k+1} - y^{k+1}).$$

相对误差准则为

$$\frac{2}{\beta}\left|\left\langle z_1^k - x^{k+1}, d_1^{k+1}\right\rangle\right| + \tau\left\|d_1^{k+1}\right\|^2 \leq \sigma_1\left\|x^{k+1} - y^k\right\|^2,$$

$$\frac{2}{\beta}\left|\left\langle z_2^k - y^{k+1}, d_2^{k+1}\right\rangle\right| + \tau\left\|d_2^{k+1}\right\|^2 \leq \sigma_2\left\|x^{k+1} - y^k\right\|^2 + \sigma_3(1-\tau)\left\|x^{k+1} - y^{k+1}\right\|^2.$$

更新

$$\lambda^{k+1} = \lambda^k - \tau\beta(x^{k+1} - y^{k+1}).$$

子问题显式解

在该模型中两个子问题都有精确闭式形式，可作为误差准则的内层目标。

$$x^{k+1} = \mathcal{S}_{\eta/\beta}\left(y^k + \frac{\lambda^k}{\beta}\right).$$

$$\left(A^\top A + (\beta + 2\gamma)I\right) y^{k+1} = A^\top b + \beta x^{k+1} - \lambda^k.$$

若 $AA^\top = I$，令 $a = \beta + 2\gamma$，则

$$y^{k+1} = \frac{1}{a}\left(I - \frac{A^\top A}{a+1}\right)\left(A^\top b + \beta x^{k+1} - \lambda^k\right).$$

2.5 GrpADMM 与 AGrpADMM

GrpADMM/AGrpADMM 可用于弹性网络的 LAD 型强凸模型

$$\min_{x,w}\left\{\mu_1 \|x\|_1 + \mu_2 \|x\|^2 + \|w - c\|_1 \;\middle|\; Kx - w = 0\right\},$$

其参数、框架和显式解见第一节 AGrpADMM。若要直接测试平方损失型 elastic-net 模型，也可令约束为 $x - y = 0$，并把 GrpADMM 写成

$$p(x) = \eta \|x\|_1, \qquad q(y) = \gamma \|y\|^2 + \frac{1}{2}\|Ay - b\|^2, \qquad H = I.$$

当 $S = s_x I, T = s_y I$ 时，GrpADMM 子问题为

$$x^n = \mathcal{S}_{\tau\eta/s_x}\left(u^n - \frac{\tau}{s_x}\lambda^{n-1}\right),$$

$$\left(A^\top A + \left(2\gamma + \sigma + \frac{s_y}{1}\right) I\right) y^n = A^\top b + \lambda^{n-1} + \sigma x^n + s_y y^{n-1},$$

其中第二式对应非加速、固定 $T = s_y I$ 的写法；若 $T = 0$，去掉 $s_y y^{n-1}$ 并将系数中的 s_y 置零。

3 全变分图像去噪实验

3.1 实验模型与数据生成

设 $c = x^* + e$ 为含噪图像，$D_i x \in \mathbb{R}^2$ 为第 i 个像素处的水平和垂直差分。TV 去噪模型为

$$\min_x \ \frac{\mu}{2}\|x-c\|^2 + \sum_i \|D_i x\|_2 .$$

引入 $w_i = D_i x$，得到

$$\min_{x,w} \left\{ \frac{\mu}{2}\|x-c\|^2 + \sum_i \|w_i\|_2 \,\middle|\, Dx - w = 0 \right\}.$$

其中

$$p(x) = \frac{\mu}{2}\|x-c\|^2, \qquad q(w) = \sum_i \|w_i\|_2, \qquad H = D.$$

建议实验设置：

$$\text{image} = \texttt{cameraman}, \quad 256 \times 256, \quad \mu = 11,$$

先将像素缩放至 $[0,1]$，加入均值 0、标准差 0.01 的高斯噪声。初值取

$$x^0 = c, \qquad (w^0, \lambda^0) = (0,0).$$

评价指标可用

$$\frac{|\Phi(x^k,w^k) - \Phi^*|}{|\Phi^*|}, \qquad \left\|Dx^k - w^k\right\|, \qquad \mathrm{SNR}(x^k).$$

3.2 GrpADMM

参数

文献 TV 实验采用

$$\sigma = 10, \qquad S = I, \qquad T = 0, \qquad \tau = \frac{\psi}{\sigma\|D\|^2}, \qquad \psi = 1.618.$$

算法框架

$$u^n = \frac{\psi-1}{\psi}x^{n-1} + \frac{1}{\psi}u^{n-1},$$

$$x^n = \arg\min_x \left\{ \frac{\mu}{2}\|x-c\|^2 + \left\langle \lambda^{n-1}, Dx - w^{n-1}\right\rangle + \frac{1}{2\tau}\|x-u^n\|_S^2 \right\},$$

$$w^n = \arg\min_w \left\{ \sum_i \|w_i\|_2 + \left\langle \lambda^{n-1}, Dx^n - w\right\rangle + \frac{\sigma}{2}\|Dx^n - w\|^2 \right\},$$

$$\lambda^n = \lambda^{n-1} + \sigma(Dx^n - w^n).$$

子问题显式解

若 $S = s_x I$，则

$$\left(\mu I + \frac{s_x}{\tau} I\right) x^n = \mu c + \frac{s_x}{\tau} u^n - D^\top \lambda^{n-1}.$$

特别地，$S = I$ 时

$$x^n = \frac{\mu c + \tau^{-1} u^n - D^\top \lambda^{n-1}}{\mu + \tau^{-1}}.$$

对每个像素块 i，

$$w_i^n = \mathcal{G}_{1/\sigma}\left((Dx^n)_i + \frac{\lambda_i^{n-1}}{\sigma}\right).$$

3.3 AGrpADMM

参数

由于 $p(x) = \frac{\mu}{2}\|x - c\|^2$ 强凸，可使用 AGrpADMM。文献 TV 实验取

$$\rho = 1, \qquad S = \mu I, \qquad T = 0.1I, \qquad \psi = 1.618,$$
$$\sigma_0 = \rho, \qquad \tau_0 = \frac{\psi \lambda_{\min}(S)}{\sigma_0 \|D\|^2}.$$

算法框架

$$u^n = \frac{\psi - 1}{\psi} x^{n-1} + \frac{1}{\psi} u^{n-1},$$
$$x^n = \arg\min_x \left\{ \frac{\mu}{2}\|x - c\|^2 + \left\langle \lambda^{n-1}, Dx - w^{n-1} \right\rangle + \frac{1}{2\tau_{n-1}} \|x - u^n\|_S^2 \right\},$$
$$w^n = \arg\min_w \left\{ \sum_i \|w_i\|_2 + \left\langle \lambda^{n-1}, Dx^n - w \right\rangle + \frac{\sigma_{n-1}}{2}\|Dx^n - w\|^2 + \frac{1}{2t_{n-1}} \left\|w - w^{n-1}\right\|_T^2 \right\},$$
$$\lambda^n = \lambda^{n-1} + \sigma_{n-1}(Dx^n - w^n),$$
$$t_n = \frac{1 + \sqrt{1 + 4t_{n-1}^2}}{2}, \qquad \sigma_n = \rho t_n, \qquad \tau_n = \frac{\psi \lambda_{\min}(S)}{\sigma_n \|D\|^2}.$$

子问题显式解

若 $S = s_x I$，则

$$\left(\mu I + \frac{s_x}{\tau_{n-1}} I\right) x^n = \mu c + \frac{s_x}{\tau_{n-1}} u^n - D^\top \lambda^{n-1}.$$

若 $T = t_w I$，令

$$a_w = \sigma_{n-1} + \frac{t_w}{t_{n-1}}, \qquad v_i = \frac{\sigma_{n-1}(Dx^n)_i + \lambda_i^{n-1} + (t_w/t_{n-1}) w_i^{n-1}}{a_w}.$$

则

$$w_i^n = \mathcal{G}_{1/a_w}(v_i).$$

3.4 双子问题非精确准则 IADMM

参数

IADMM 文献中 TV 去噪常用单子问题非精确形式，但双子问题非精确准则也可写成统一框架：

$$\beta > 0, \quad \tau \in (0, 1], \quad \sigma_1, \sigma_2 \geq 0, \quad \sigma_1 + \sigma_2 < 1, \quad \sigma_3 \in [0, 1).$$

若希望复现实验中允许大步长，可使用单子问题非精确设置：

$$\sigma = 0.99, \qquad \alpha = 0.4, \qquad \tau = 1.468.$$

算法框架

使用 IADMM 符号

$$\widehat{\mathcal{L}}_\beta(x, w; \lambda) = \frac{\mu}{2} \|x - c\|^2 + \sum_i \|w_i\|_2 - \langle \lambda, Dx - w \rangle + \frac{\beta}{2} \|Dx - w\|^2 .$$

双子问题非精确迭代为

$$x^{k+1} \approx \arg\min_x \widehat{\mathcal{L}}_\beta(x, w^k; \lambda^k), \qquad w^{k+1} \approx \arg\min_w \widehat{\mathcal{L}}_\beta(x^{k+1}, w; \lambda^k),$$

并按第一节 IADMM 的两个相对误差准则检查 d_1^{k+1}, d_2^{k+1}，最后更新

$$\lambda^{k+1} = \lambda^k - \tau\beta(Dx^{k+1} - w^{k+1}).$$

子问题显式解

x-子问题为线性系统

$$\left(\mu I + \beta D^\top D\right) x^{k+1} = \mu c + D^\top \left(\lambda^k + \beta w^k\right).$$

若采用 IADMM 原文的标度 $\frac{1}{2\mu} \|x - c\|^2 + \|w\|$，则等价写成

$$\left(I + \mu\beta D^\top D\right) x^{k+1} = c + \mu D^\top(\lambda^k + \beta w^k).$$

可用 CG 近似求解，并用相对误差准则控制内层停止。

w-子问题按像素块闭式求解：

$$w_i^{k+1} = \mathcal{G}_{1/\beta}\left((Dx^{k+1})_i - \frac{\lambda_i^k}{\beta}\right).$$

若 w-子问题精确求解，则可令 $d_2^{k+1} = 0$，双子问题准则退化为仅 x-子问题需要内层迭代。

3.5 PADMC

参数

为得到显式 x-更新，可取线性化近端矩阵

$$S_x = r_x I - \beta D^\top D, \qquad r_x > \beta \|D\|^2, \qquad S_w = s_w I, \quad s_w \geq 0.$$

凸组合参数取

$$\alpha_x, \alpha_w \in (0, 2].$$

算法框架

$$\bar{x}^{k+1} = \alpha_x x^k + (1-\alpha_x)\bar{x}^k, \qquad \bar{w}^{k+1} = \alpha_w w^k + (1-\alpha_w)\bar{w}^k,$$

$$x^{k+1} = \arg\min_x \left\{ \frac{\mu}{2}\|x-c\|^2 + \left\langle \lambda^k, Dx - w^k \right\rangle + \frac{\beta}{2}\left\|Dx - w^k\right\|^2 + \frac{1}{2}\left\|x - \bar{x}^{k+1}\right\|_{S_x}^2 \right\},$$

$$w^{k+1} = \arg\min_w \left\{ \sum_i \|w_i\|_2 + \left\langle \lambda^k, Dx^{k+1} - w \right\rangle + \frac{\beta}{2}\left\|Dx^{k+1} - w\right\|^2 + \frac{s_w}{2}\left\|w - \bar{w}^{k+1}\right\|^2 \right\},$$

$$\lambda^{k+1} = \lambda^k + \beta(Dx^{k+1} - w^{k+1}).$$

子问题显式解

由 $S_x = r_x I - \beta D^\top D$ 消去 $D^\top D$ 项，得到

$$(\mu + r_x)x^{k+1} = \mu c + r_x \bar{x}^{k+1} - D^\top \left[\lambda^k + \beta(D\bar{x}^{k+1} - w^k)\right],$$

即

$$x^{k+1} = \frac{\mu c + r_x \bar{x}^{k+1} - D^\top[\lambda^k + \beta(D\bar{x}^{k+1} - w^k)]}{\mu + r_x}.$$

令

$$a_w = \beta + s_w, \qquad v_i = \frac{\beta(Dx^{k+1})_i + \lambda_i^k + s_w \bar{w}_i^{k+1}}{a_w}.$$

则

$$w_i^{k+1} = \mathcal{G}_{1/a_w}(v_i).$$

3.6 APADMC

参数

TV 模型中强凸项在 x-块。为使用 APADMC，可交换变量顺序，把强凸块作为第二块：

$$\min_{w,x} \left\{ \sum_i \|w_i\|_2 + \frac{\mu}{2}\|x-c\|^2 \,\middle|\, -w + Dx = 0 \right\}.$$

此时强凸函数为第二块 x，对应矩阵 $B = D$，因此

$$\beta_k = \frac{\mu(k+1)}{3\|D\|^2}.$$

取

$$S_w = s_w I, \qquad S_x = s_x I, \qquad \alpha_x, \alpha_w \in (0, 2].$$

算法框架

构造

$$\bar{w}^{k+1} = \alpha_w w^k + (1-\alpha_w)\bar{w}^k, \qquad \bar{x}^{k+1} = \alpha_x x^k + (1-\alpha_x)\bar{x}^k.$$

先更新非强凸块 w：

$$w^{k+1} = \arg\min_w \left\{ \sum_i \|w_i\|_2 + \left\langle \lambda^k, Dx^k - w \right\rangle + \frac{\beta_k}{2} \left\| Dx^k - w \right\|^2 + \frac{1}{2\beta_k} \left\| w - \bar{w}^{k+1} \right\|_{S_w}^2 \right\}.$$

再更新强凸块 x：

$$x^{k+1} = \arg\min_x \left\{ \frac{\mu}{2} \|x - c\|^2 + \left\langle \lambda^k, Dx - w^{k+1} \right\rangle + \frac{\beta_k}{2} \left\| Dx - w^{k+1} \right\|^2 + \frac{1}{2\beta_k} \left\| x - \bar{x}^{k+1} \right\|_{S_x}^2 \right\}.$$

乘子更新

$$\lambda^{k+1} = \lambda^k + \beta_k (Dx^{k+1} - w^{k+1}).$$

子问题显式解

若 $S_w = s_w I$，令

$$a_{w,k} = \beta_k + \frac{s_w}{\beta_k}, \qquad v_i = \frac{\beta_k (Dx^k)_i + \lambda_i^k + (s_w/\beta_k)\bar{w}_i^{k+1}}{a_{w,k}}.$$

则

$$w_i^{k+1} = \mathcal{G}_{1/a_{w,k}}(v_i).$$

若 $S_x = s_x I$，则 x-子问题线性系统为

$$\left(\mu I + \beta_k D^\top D + \frac{s_x}{\beta_k} I \right) x^{k+1} = \mu c - D^\top \lambda^k + \beta_k D^\top w^{k+1} + \frac{s_x}{\beta_k} \bar{x}^{k+1}.$$

在周期边界条件下，$D^\top D$ 具有 BCCB 结构，可用二维 FFT 快速求解。

4 算法与问题对应关系汇总

算法	适用问题	推荐参数	子问题求解特征
GrpADMM	LAD、TV、平方损失型 elastic-net	$\psi = 1.618$，$\tau = \psi/(\sigma \|H\|^2)$；LAD 取 $\sigma = 1$，TV 取 $\sigma = 10$	LAD 的 x, w 均为 shrinkage；TV 的 x 为对角线性系统，w 为 group shrinkage
AGrpADMM	强凸 LAD 型 elastic-net、TV；不用于基础 LAD 默认对比	$\rho = 0.001$ 或 1，$S \preceq \gamma I$，$\sigma_n = \rho t_n$，$\tau_n = \psi\lambda_{\min}(S)/(\sigma_n \|H\|^2)$	强凸块给出闭式线性更新；非光滑块为 shrinkage 或 group shrinkage
IADMM 双子问题非精确准则	LAD、elastic-net、TV	$\tau \in (0, 1]$，$\sigma_1 + \sigma_2 < 1$，$\sigma_3 \in [0, 1)$；若用单子问题大步长 TV，可取 $\alpha = 0.4, \tau = 1.468$	子问题可精确时直接闭式；不可精确时用 CG/FISTA/近端梯度直到满足相对误差准则
PADMC	LAD、elastic-net、TV	$\alpha_x, \alpha_w \in (0, 2]$；elastic-net 常取 $\alpha_y = 1, \alpha_x = 1$ 或 2；TV 可取线性化 $S_x = r_x I - \beta H^\top H$	通过线性化近端项使 x-子问题闭式；非光滑块由 shrinkage/group shrinkage 给出
APADMC	elastic-net、TV；LAD 需加入二次强凸项，不用于基础 LAD 默认对比	$\beta_k = \mu(k+1)/(3\|B\|^2)$，近端矩阵缩放为 S/β_k	与 PADMC 类似，但每步参数变化；强凸块通常为线性系统，可用 Hadamard/FFT 加速

建议的实验输出

建议每组实验统一输出如下信息：

1. 问题规模、随机种子、噪声水平、正则化参数；
2. 每个算法的外层迭代数、内层迭代数和 CPU 时间；
3. 函数值残差与可行性违反的曲线；
4. LAD/elastic-net 的恢复误差 $\left\|x^k - x^\natural\right\| / \left\|x^\natural\right\|$；

5. TV 去噪的 PSNR 或 SNR;

6. 每个算法实际使用的 $\beta, \sigma, \tau, \psi, \alpha_x, \alpha_y, \rho$ 等参数。