<style> body, .paper-notes { font-family: "Times New Roman", "SimSun", "宋体", serif; line-height: 1.7; } .paper-notes table { border-collapse: collapse; } .paper-notes th, .paper-notes td { border: 1px solid #999; padding: 6px 10px; } .paper-notes code, .paper-notes pre { font-family: "Consolas", "Times New Roman", "SimSun", monospace; } </style>

参考文献算法框架与数值实验整理

本文档整理 参考文献 目录下三篇文献的算法框架、数值实验步骤与可复现细节：

1. Jiaxin Xie, *On inexact ADMMs with relative error criteria*, Computational Optimization and Applications, 2018. 文件：`IADMM.pdf`。
2. Danqing Zhou, Haiwen Xu, Junfeng Yang, *Proximal Alternating Direction Method of Multipliers with Convex Combination Proximal Centers*, Asia-Pacific Journal of Operational Research, 2024. 文件：`PADMC.pdf`。
3. Hongmei Chen, Guoyong Gu, Junfeng Yang, *A golden ratio proximal alternating direction method of multipliers for separable convex optimization*, Journal of Global Optimization, 2023. 文件：`GrpADMM.pdf`。

---

1. IADMM：相对误差准则下的非精确 ADMM

1.1 基本模型

文献考虑二块可分离凸优化问题

$$\min_{x\in X,\, y\in Y}\{f(x)+g(y)\mid Ax+By=b\}.$$

增广拉格朗日函数为

$$L_\beta(x,y;\lambda)=f(x)+g(y)-\langle\lambda,Ax+By-b\rangle+\frac{\beta}{2}\|Ax+By-b\|^2.$$

经典 ADMM 依次精确求解 x-子问题和 y-子问题，再更新乘子

$$\lambda^{k+1}=\lambda^k-\tau\beta(Ax^{k+1}+By^{k+1}-b).$$

该文的核心是：允许一个或两个子问题只被非精确求解，但用相对误差准则控制误差；当只允许第一个子问题非精确时，可选择大于 1 的乘子步长。

1.2 算法 1：单子问题非精确 ADMM

适用情形：x-子问题非精确求解，y-子问题可精确求解或有闭式解。

参数：

- $\beta>0$；
- $\sigma\in[0,1)$；
- $\alpha\in(0,1)$，令 $\gamma=1-\alpha$；
- 步长

$$\tau\in\left(0,\frac{2\gamma-1+\sqrt{4\gamma^2+1}}{2\gamma}\right).$$

当 α 较小时，τ 的上界可接近黄金比例 $(1+\sqrt{5})/2$。文献实验中 $\alpha = 0.4$ 时采用 $\tau = 1.468$。

迭代框架：

1. 给定 $y^0 \in \operatorname{dom} g$，$(w^0, \lambda^0) \in X \times Z$。
2. 对 $k = 0, 1, \ldots$，近似求解

$$x^{k+1} \approx \arg\min_x L_\beta(x, y^k; \lambda^k),$$

并要求存在

$$d^{k+1} \in \partial f(x^{k+1}) - A^*[\lambda^k - \beta(Ax^{k+1} + By^k - b)]$$

满足相对误差准则

$$\frac{2}{\beta}|\langle w^k - x^{k+1}, d^{k+1}\rangle| + \|d^{k+1}\|^2 \le \sigma\alpha\|Ax^{k+1} + By^k - b\|^2.$$

3. 精确求解

$$y^{k+1} := \arg\min_y L_\beta(x^{k+1}, y; \lambda^k).$$

4. 更新

$$\lambda^{k+1} := \lambda^k - \tau\beta(Ax^{k+1} + By^{k+1} - b),$$

$$w^{k+1} := w^k - \beta d^{k+1}.$$

实现要点：

- 若 x-子问题精确解存在，则可令 $d^{k+1} = 0$，误差准则自动满足。
- α 控制"误差容忍度"和"可用大步长"之间的折中：过小的 α 虽允许更大 τ，但会使内层迭代过多。
- 文献实验表明 $\alpha = 0.4$ 在图像去噪测试中较为稳健。

1.3 算法 2：双子问题非精确 ADMM

适用情形：两个 ADMM 子问题都只近似求解。

参数：

- $\beta > 0$，$\tau \in (0, 1]$；
- $\sigma_1, \sigma_2 \ge 0$，且 $\sigma_1 + \sigma_2 < 1$；
- $\sigma_3 \in [0, 1)$。

迭代框架：

1. 近似求解 x-子问题，并令

$$d_1^{k+1} \in \partial f(x^{k+1}) - A^*[\lambda^k - \beta(Ax^{k+1} + By^k - b)].$$

要求

$$\frac{2}{\beta}|\langle w_1^k - x^{k+1}, d_1^{k+1}\rangle| + \tau\|d_1^{k+1}\|^2 \le \sigma_1\|Ax^{k+1} + By^k - b\|^2.$$

2. 近似求解 y-子问题，并令

$$d_2^{k+1} \in \partial g(y^{k+1}) - B^*[\lambda^k - \beta(Ax^{k+1} + By^{k+1} - b)].$$

要求

$$\frac{2}{\beta}|\langle w_2^k - y^{k+1}, d_2^{k+1}\rangle| + \tau\|d_2^{k+1}\|^2 \le \sigma_2\|Ax^{k+1} + By^k - b\|^2 + \sigma_3(1-\tau)\|Ax^{k+1} + By^{k+1} - b\|^2.$$

3. 更新

$$\lambda^{k+1} := \lambda^k - \tau\beta(Ax^{k+1} + By^{k+1} - b),$$

$$w_1^{k+1} := w_1^k - \tau\beta d_1^{k+1}, \qquad w_2^{k+1} := w_2^k - \tau\beta d_2^{k+1}.$$

算法 2 的 $\tau \le 1$，因此不能像算法 1 那样直接使用大于 1 的乘子步长。若取 $\tau = 1$，则退化为既有相对误差非精确 ADMM 的形式。

1.4 数值实验 1：TV 图像去噪

实验目标：

- 验证算法 1 中额外参数 α 能通过允许较大 τ 提升效率；
- 比较精确 ADMM、非精确 ADMM 以及不同步长下的表现。

模型：

$$\min_x \|x\|_{\mathrm{TV}} + \frac{1}{2\mu}\|x - c\|^2.$$

令 $D = [D_1, D_2]^T$，其中 D_1, D_2 为水平与垂直差分算子，$\|x\|_{\mathrm{TV}} = \|Dx\|$。引入 $y = Dx$ 后写成

$$\min_{x,y}\left\{\|y\|_1 + \frac{1}{2\mu}\|Ax - c\|^2 \mid Dx - y = 0\right\}.$$

ADMM 中 x-子问题转化为线性系统

$$(A^TA + \mu\beta D^TD)x^{k+1} = \mu D^T(\lambda^k + \beta y^k) + A^Tc.$$

实验步骤：

1. 选取测试图像 `Pirate` 与 `Moon`。
2. 将原始像素缩放至 $[0,1]$。
3. 加入零均值白高斯噪声，噪声水平记为 δ。
4. 初始化 $x^0 = c$，$(y^0, \lambda^0, w^0) = 0$。
5. 每次外层迭代中，用 CG 近似求解 x-线性系统，并用上一外层迭代的 x^k 作为 CG 热启动点。
6. y-子问题使用 soft shrinkage 闭式更新。
7. 手动调节 μ 以取得较高 PSNR；β 通过试验选取表现较好的值。
8. 对 $\alpha = 0.005, 0.1, 0.2, \ldots, 1$ 比较 CPU 时间和累计内层迭代数。

内层 CG 停止准则：

$$\frac{\|Cx - b\|}{\max\{\|b\|, 1\}} < 10^{-8},$$

其中

$$C = A^TA + \mu\beta D^TD, \qquad b = \mu D^T(\lambda^k + \beta y^k) + A^Tc.$$

ADMM 外层停止准则：

$$\max\left\{\frac{\|Dx^k - y^k\|}{\max\{\|Dx^k\|, \|y^k\|, 1\}}, \frac{\|\beta D^T(y^{k+1} - y^k)\|}{\max\{1, \|D^T\lambda^k\|\}}\right\} < \eta.$$

指标：

- 外层迭代数 `Iter`；
- 内层 CG 累计迭代数 `Inniter`；
- CPU 时间；
- PSNR。

关键参数与现象：

- $\sigma = 0.99$；
- $\alpha = 0.4$ 时 $\tau = 1.468$，记为 `iAD-CG.4`；
- $\alpha = 1$ 时 $\tau = 1$，记为 `iAD-CG1`；
- 对 `Pirate` 和 `Moon`，$\alpha = 0.4$ 的 CPU 时间最低；
- `iAD-CG.4` 与精确 ADMM 的 PSNR 基本相同，但 CPU 时间更短。

1.5 数值实验 2：随机生成的 analysis sparse recovery

模型仍为

$$\min_x \|Dx\|_1 + \frac{1}{2\mu}\|Ax - c\|^2.$$

数据生成：

1. 测量矩阵 A 为标准高斯随机矩阵，列归一化。
2. 分析算子 D 有两类：
   - 随机 tight frame，满足 $D^TD = I$，由高斯矩阵 QR 分解得到；
   - $n \times n$ 离散余弦变换矩阵 DCT。
3. 原始信号 $x = D^Ty$，其中 y 为 s-稀疏向量。
4. 噪声 $e \sim N(0, 1)$，观测 $c = Ax + \delta e$，$\delta = 10^{-3}$。

实验设置：

- $\mu = 10^3$；
- $p = n$；
- $s = \mathrm{round}(0.1m)$；
- 初始点 $x^0 = A^Tb$；
- 每组规模运行 5 次取平均；
- 比较 `AD-CG`、`iAD-CG1`、`iAD-CG.4` 与 `SFISTA`；
- 步长分别为 1.618、1、1.468。

评价指标：

$$\mathrm{Error} := \frac{\|x_{\mathrm{sol}} - x\|}{\|x\|}.$$

实验结论：

- 非精确 ADMM 普遍快于经典 ADMM；
- `iAD-CG.4` 通常比单位步长的 `iAD-CG1` 更快；
- 在随机 tight frame 与 DCT 两类数据上，非精确 ADMM 至少比 `SFISTA` 快约 2 倍，同时误差量级相近。

---

2. PADMC：凸组合近端中心的 proximal ADMM

2.1 基本模型

文献考虑

$$\min_{x,y} f(x)+g(y) \quad \text{s.t.} \quad Ax+By=b.$$

当 $b=0$、$B=-I$ 时，可化为复合模型

$$\min_x f(x)+g(Ax).$$

PADMC 的核心思想是：在 proximal ADMM 的近端项中，不再以当前迭代点作为近端中心，而是用当前点与历史近端中心的凸组合构造新的近端中心。

2.2 基础 PADMC 框架

给定 x^0,y^0,λ^0，令 $\bar{x}^0=x^0,\bar{y}^0=y^0$。对 $k=0,1,\dots$，执行：

1. **构造凸组合近端中心**

$$\bar{z}^{k+1}=\alpha_z z^k+(1-\alpha_z)\bar{z}^k, \qquad z\in\{x,y\},$$

其中 $\alpha_x,\alpha_y\in(0,2]$。文中称为 convex combination，但允许参数超过 1。

2. **求解 x-子问题**

$$x^{k+1}\in\arg\min_x L_\beta(x,y^k,\lambda^k)+\frac{1}{2}\|x-\bar{x}^{k+1}\|_{S_x}^2.$$

3. **求解 y-子问题**

$$y^{k+1}\in\arg\min_y L_\beta(x^{k+1},y,\lambda^k)+\frac{1}{2}\|y-\bar{y}^{k+1}\|_{S_y}^2.$$

4. **更新乘子**

$$\lambda^{k+1}=\lambda^k+\beta(Ax^{k+1}+By^{k+1}-b).$$

其中 $S_x\succeq 0, S_y\succeq 0$。当 $\alpha_x=\alpha_y=1$ 时，PADMC 退化为经典 PADMM。

2.3 强凸加速 PADMC

当 g 为 μ-强凸函数时，文献提出加速形式。若强凸函数是 f，可交换 (f,A,x) 与 (g,B,y) 的角色。

主要更新：

$$\beta_k=\frac{\mu(k+1)}{3\|B\|^2}.$$

然后用 β_k 替代固定 β，并将近端权重缩放为 S_x/β_k、S_y/β_k：

$$x^{k+1} \in \arg\min_x L_{\beta_k}(x, y^k, \lambda^k) + \frac{1}{2\beta_k}\|x - \bar{x}^{k+1}\|_{S_x}^2,$$

$$y^{k+1} \in \arg\min_y L_{\beta_k}(x^{k+1}, y, \lambda^k) + \frac{1}{2\beta_k}\|y - \bar{y}^{k+1}\|_{S_y}^2,$$

$$\lambda^{k+1} = \lambda^k + \beta_k(Ax^{k+1} + By^{k+1} - b).$$

该变体可得到 $O(1/K^2)$ 的遍历收敛率。

2.4 带松弛因子的 PADMC-r

文献还引入对偶松弛因子 θ，仅修改乘子更新：

$$\lambda^{k+1} = \lambda^k + \beta\theta(Ax^{k+1} + By^{k+1} - b),$$

其中

$$\theta \in \left(0, \frac{1+\sqrt{5}}{2}\right].$$

数值实验中取 $\theta = 1.618$，记为 `PADMC-r`。

2.5 数值实验 1：LASSO

实验目标：

- 检验 α_x, α_y 不同取值对 PADMC 收敛行为的影响；
- 比较 PADMM 与 PADMC；
- 检查松弛因子 $\theta = 1.618$ 对可行性违反的改善。

原问题：

$$\min_x \eta\|x\|_1 + \frac{1}{2}\|Ax - b\|^2.$$

引入辅助变量 $y = Ax$，得到

$$\min_{x,y} \eta\|x\|_1 + \frac{1}{2}\|y - b\|^2 \quad \text{s.t.} \quad Ax - y = 0.$$

数据生成：

1. 生成 $K \in R^{q\times n}$，元素独立服从 $N(0,1)$。
2. 用相关参数 $\nu \in (0,1)$ 按列构造 ill-conditioned 感知矩阵：

$$A_1 = K_1/\sqrt{1-\nu^2}, \qquad A_j = \nu A_{j-1} + K_j.$$

3. 生成 s-稀疏真值 $x^\star$：非零位置均匀随机，非零值服从 $N(0,1)$。
4. 观测 $b = Ax^\star + \omega$，噪声分量服从 $N(0, 0.01)$。

实验设置：

- $(q,n,s)=(640,2000,100)$；
- $\nu=0.5$；
- $\eta=0.01$；
- 初值 $(x^0,y^0,\lambda^0)=(0,b,0)$；
- $S_x=\tau I-\beta A^TA$，$S_y=100I$；
- $\beta=0.005$，$\tau=1.001\beta\|A\|^2$；
- 最优函数值 F_{opt} 由 CVX 求得。

比较设置：

1. 固定 $\alpha_y=1$，比较

$$\alpha_x\in\{1,2,1.5,0.5\}.$$

   其中 $\alpha_x=\alpha_y=1$ 对应 PADMM；$\alpha_x=2,1.5,0.5$ 分别记为 PADMC-1、PADMC-2、PADMC-3。
2. 固定 $\alpha_x=1$，比较

$$\alpha_y\in\{1,2,1.5,0.5\}.$$

   对应 PADMM 与 PADMC-4/5/6。
3. 在类似设置下，令 $T=0$，比较 PADMM、PADMC(\alpha_x,\alpha_y)=(2,1)、PADMM-r 与 PADMC-r，其中 $\theta=1.618$。

指标：

- 相对函数值残差；
- 可行性违反；
- 横轴为迭代次数。文献说明各算法单步成本近似相同，因此主要报告迭代数，CPU 时间趋势类似。

实验结论：

- 固定 $\alpha_y=1$ 时，较大的 α_x 通常带来更快下降，$\alpha_x=2$ 表现最好；
- 固定 $\alpha_x=1$ 时，不同 α_y 的差异较小；
- 引入松弛因子后，PADMM-r 与 PADMC-r 在若干百步后可更快降低可行性违反；
- 凸组合近端中心仍能保持小幅优势。

2.6 数值实验 2：Elastic-net regularization

实验目标：

- 验证强凸加速 PADMC，即 APADMC；
- 比较加速与非加速、$\alpha_x=1$ 与 $\alpha_x=2$ 的差异。

原问题：

$$\min_x \eta\|x\|_1+\gamma\|x\|^2+\frac{1}{2}\|Ax-b\|^2.$$

引入辅助变量后：

$$\min_{x,y} \eta\|x\|_1+\gamma\|y\|^2+\frac{1}{2}\|Ay-b\|^2\quad\text{s.t.}\quad x-y=0.$$

其中

$$g(y)=\gamma\|y\|^2+\frac{1}{2}\|Ay-b\|^2$$

为 2γ-强凸。

数据与矩阵：

1. 使用 Walsh-Hadamard transform 生成矩阵。
2. 从归一化 Hadamard 矩阵中随机抽取部分行作为 A，使 $AA^T=I$。
3. 真值稀疏向量和观测向量按 LASSO 实验同样方式生成。

实验设置：

- $(q,n,s)=(2000,8192,1500)$；
- $\eta=0.01$，$\gamma=0.005$；
- $S_x=100I$，$S_y=50I$；
- 固定 $\alpha_y=1$，比较 $\alpha_x=1,2$；
- 初值 $(x^0,y^0,\lambda^0)=(0,0,0)$；
- 强凸参数取 $\mu=2\gamma$；
- F_{opt} 由 APADMC 运行足够多步得到。

算法命名：

- 加速算法、$\alpha_x=1$：APADMM；
- 加速算法、$\alpha_x=2$：APADMC；
- 非加速算法、$\alpha_x=1$：PADMM；
- 非加速算法、$\alpha_x=2$：PADMC。

指标：

- 函数值残差；
- 可行性违反；
- 横轴为迭代次数。

实验结论：

- 加速算法明显优于非加速算法；
- APADMC 略优于 APADMM，说明更大的凸组合参数可能带来额外收益。

---

3. GrpADMM：黄金比例 proximal ADMM

3.1 基本模型

文献考虑

$$\min\{g(x)+f(w)\mid Ax+Bw=b,\ x\in R^q,\ w\in R^p\}.$$

设黄金比例

$$\phi=\frac{1+\sqrt{5}}{2}.$$

GrpADMM 将黄金比例凸组合技术引入 proximal ADMM，目标是在保持结构可分与子问题易解的同时，放宽步长条件。

3.2 基础 GrpADMM 框架

参数与初始化：

- $S \in S^q_{++}$，$T \in S^p_{++}$；
- $\sigma, \tau > 0$，$\psi \in (1, \phi]$；
- 要求

$$\sigma\tau\|A\|^2 < \psi\lambda_{\min}(S).$$

- 初值 x^0, w^0, y^0，令 $u^0 = x^0$。

迭代（$n = 1, 2, \ldots$）：

1. **黄金比例近端中心**

$$u^n = \frac{\psi - 1}{\psi} x^{n-1} + \frac{1}{\psi} u^{n-1}.$$

2. **求解 x-子问题**

$$x^n = \arg\min_x L(x, w^{n-1}, y^{n-1}) + \frac{1}{2\tau}\|x - u^n\|_S^2.$$

3. **求解 w-子问题**

$$w^n = \arg\min_w L_\sigma(x^n, w, y^{n-1}) + \frac{1}{2}\|w - w^{n-1}\|_T^2.$$

4. **更新乘子**

$$y^n = y^{n-1} + \sigma(Ax^n + Bw^n - b).$$

与 PADMM 的区别：

- PADMM 的 x-近端中心通常是 x^{n-1}；
- GrpADMM 的 x-近端中心是 u^n，即由当前历史迭代构造的黄金比例凸组合中心；
- 在特定取值下，GrpADMM 的条件可放宽到 $\tau\sigma\|A\|^2 < \psi$，而线性化 PADMM 通常要求 < 1。

3.3 强凸加速 AGrpADMM

当 g 为 γ-强凸函数时，采用变参数加速算法。

初始化：

- $T \succ 0$，$0 \prec S \preceq \gamma I$；
- $\rho > 0$，$\psi \in (1, \phi]$；
- $\sigma_0 = \rho$；
- $\tau_0 = \psi\lambda_{\min}(S)/(\sigma_0\|A\|^2)$；
- $u^0 = x^0$，$t_0 = 1$。

迭代：

1. 仍使用

$$u^n = \frac{\psi - 1}{\psi} x^{n-1} + \frac{1}{\psi} u^{n-1}.$$

2. 求解

$$x^n = \arg\min_x L(x, w^{n-1}, y^{n-1}) + \frac{1}{2\tau_{n-1}} \|x - u^n\|_S^2,$$

$$w^n = \arg\min_w L_{\sigma_{n-1}}(x^n, w, y^{n-1}) + \frac{1}{2t_{n-1}} \|w - w^{n-1}\|_T^2,$$

$$y^n = y^{n-1} + \sigma_{n-1}(Ax^n + Bw^n - b).$$

3. 更新加速参数

$$t_n = \frac{1 + \sqrt{1 + 4t_{n-1}^2}}{2},$$

$$\sigma_n = \rho t_n, \qquad \tau_n = \frac{\psi \lambda_{\min}(S)}{\sigma_n \|A\|^2}.$$

该算法可将遍历收敛率从 $O(1/N)$ 提升到 $O(1/N^2)$。

3.4 数值实验 1：LAD 稀疏恢复

实验目标：

- 比较不同 ψ 对 GrpADMM 的影响；
- 比较 GrpADMM、PADMM 与标准 ADMM。

模型：

$$\min_x \{\mu \|x\|_1 + \|Kx - c\|_1\}.$$

引入 w 后：

$$\min_{x,w} \{\mu \|x\|_1 + \|w - c\|_1 \mid Kx - w = 0\}.$$

数据生成：

1. K 的元素独立服从 $N(0,1)$。
2. $x^\natural$ 为 s-稀疏信号，非零位置均匀随机，非零值由 MATLAB randn 生成。
3. 观测 $c = N(Kx^\natural)$，其中 impulsive noise 通过随机替换 5% 的 $Kx^\natural$ 分量生成，被替换值为 $\|Kx^\natural\|_\infty$ 或 $-\|Kx^\natural\|_\infty$，概率各为 0.5。

实验设置：

- $\mu = 0.05$；
- 初值 $(x^0, w^0, y^0) = (0, 0, -c)$；
- GrpADMM：$S = I$，$T = 0$，$\sigma = 1$，

$$\tau = \frac{\psi}{\sigma\|K\|^2}.$$

- x-与 w-子问题均可用 shrinkage 算子闭式求解：

$$\mathrm{Shrinkage}(x,\eta) = (|x| - \eta)_+ \circ \mathrm{sign}(x).$$

第一组比较：

- $\psi = 1.1, 1.3, 1.618$；
- 三组问题规模：

$$(p,q,s) = (600,2000,200), (1200,3000,300), (1800,4000,400).$$

- 观察相对函数值残差

$$\frac{|\Phi(x^n,w^n) - \Phi^*|}{\Phi^*}.$$

结论：更大的 ψ 通常使函数值下降更快，后续实验固定 $\psi = 1.618$。

第二组比较：

- 问题规模 $(p,q,s) = (1000,3000,100)$；
- 最大迭代数 15000；
- PADMM 取

$$S = \frac{1}{\tau}I - \sigma K^T K, \qquad \tau = \frac{1}{\sigma\|K\|^2}, \qquad T = 0.$$

- 标准 ADMM 需额外引入 z，并将 (z,w) 作为一块，x 作为另一块；其 x-子问题是最小二乘，使用 MATLAB pcg，最大 PCG 迭代数 20，停止容差 10^{-5}。

指标：

- 相对函数值残差随迭代数变化；
- 相对函数值残差随 CPU 时间变化；
- 可行性违反 $\|Kx^n - w^n\|$ 的行为类似，文献未重复展示。

结论：

- GrpADMM 与 PADMM 迭代表现接近；
- 二者 CPU 时间均优于标准 ADMM；
- 原因是 ADMM 的 x-子问题需要迭代解线性系统，而 GrpADMM/PADMM 的子问题可由 shrinkage 快速求解。

3.5 数值实验 2：强凸 LAD/Elastic-net 变体

实验目标：

- 验证 AGrpADMM 在强凸问题中的加速效果。

模型：

$$\min_{x,w}\left\{\mu_1\|x\|_1+\mu_2\|x\|^2+\|w-c\|_1 \mid Kx-w=0\right\}.$$

数据生成：

- 与 LAD 实验基本相同；
- K 采用相关高斯列构造：

$$K_1=\varrho_1\sqrt{\frac{(1-\upsilon)^2}{1-\upsilon^2}},\qquad K_j=\upsilon K_{j-1}+(1-\upsilon)\varrho_j,$$

  其中 $\varrho_j\sim N(0,I)$，$\upsilon=0.5$。

实验设置：

- $(p,q,s)=(640,2000,100)$；
- 最大迭代数 2000；
- $\mu_1=0.05$，$\mu_2=0.04$，$\sigma=1.5$；
- AGrpADMM：$\rho=0.001$，$S=\mu_2 I$，$T=0.01I$；
- ADMM、PADMM、GrpADMM 按 LAD 实验方式实现；
- 初值 $(x^0,w^0,y^0)=(0,0,-c)$。

指标：

- 相对函数值残差；
- 约束违反 $\|Kx^n-w^n\|$；
- 分别对迭代数和 CPU 时间作图。

结论：

- AGrpADMM 在迭代数和 CPU 时间上均表现最好；
- GrpADMM 与 PADMM 表现相近且优于 ADMM；
- 强凸结构被正确利用后，可显著加速分裂算法。

3.6 数值实验 3：TV 图像去噪

实验目标：

- 在图像处理任务中比较 GrpADMM、AGrpADMM、PADMM 与 ADMM；
- 观察强凸加速对函数值残差、约束违反和 SNR 的影响。

模型：

$$\min_{x\in R^{n^2}}\frac{\mu}{2}\|x-c\|^2+\sum_i\|D_i x\|_2.$$

引入 $w_i=D_i x$：

$$\min_{x,w}\left\{\frac{\mu}{2}\|x-c\|^2+\sum_i\|w_i\|_2 \mid D_i x-w_i=0,\ i=1,\dots,n^2\right\}.$$

实验设置：

- 测试图像：cameraman，大小 256×256；

- 原图像素缩放到 $[0,1]$；
- 加入均值 0、标准差 0.01 的高斯噪声；
- $\mu = 11$；
- 初始 $x^0 = c$，$(w^0, y^0) = (0,0)$；
- 各算法统一 $\sigma = 10$；
- PADMM：

$$S = \frac{1}{\tau} I - \sigma \sum_i D_i^T D_i, \qquad \tau = \frac{1}{\sigma \|A\|^2}, \qquad T = 0.$$

- GrpADMM：

$$S = I, \qquad T = 0, \qquad \tau = \frac{\psi}{\sigma \|A\|^2}.$$

- AGrpADMM：

$$\rho = 1, \qquad S = \mu I, \qquad T = 0.1 I.$$

实现细节：

- 假设周期边界条件；
- 标准 ADMM 的 x-子问题对应矩阵具有 BCCB 结构，可用二维 FFT 精确求解，复杂度 $O(N \log N)$，其中 $N = n^2$；
- g 与 f 的 proximal mapping 均有闭式表达，因此 GrpADMM/PADMM/AGrpADMM 可高效实现。

评价指标：

- 相对函数值残差；
- 约束违反；
- SNR：

$$\mathrm{SNR}(x) = 10 \log_{10} \frac{\|\bar{x} - x^*\|}{\|x - x^*\|},$$

其中 x^* 为原图，$\bar{x}$ 为原图平均灰度。

实验结论：

- 四种算法最终恢复图像的 SNR 约为 14.77 dB，说明它们求解同一凸模型后达到近似相同解；
- AGrpADMM 在迭代数和 CPU 时间上明显优于其他算法；
- ADMM、PADMM 与 GrpADMM 在该实验中表现接近，但均显著慢于 AGrpADMM。

---

4. 三篇文献的对比总结

文献	核心改进	关键参数	主要实验	主要指标	复现重点
IADMM	用相对误差准则允许 ADMM 子问题非精确求解；单子问题非精确时可使用大于 1 的乘子步长	$\alpha, \sigma, \tau, \beta$	TV 图像去噪；随机 analysis sparse recovery	CPU 时间、内层迭代数、PSNR、相对误差	CG 内层停止准则、$\alpha = 0.4$、$\tau = 1.468$、soft shrinkage
PADMC	近端中心由迭代点凸组合构造；另有强凸加速和对偶松弛变体	$\alpha_x, \alpha_y, \beta, S_x, S_y, \theta$	LASSO；Elastic-net	函数值残差、可行性违反	感知矩阵生成、CVX 最优值、$\alpha_x = 2$、$\theta = 1.618$
GrpADMM	将黄金比例凸组合引入 proximal ADMM，放宽步长条件；强凸时加速	$\psi, \sigma, \tau, S, T, \rho, t_n$	LAD 稀疏恢复；强凸变体；TV 图像去噪	函数值残差、约束违反、CPU 时间、SNR	$\psi = 1.618$、shrinkage 闭式子问题、PCG/FFT 实现细节

总体观察

- **IADMM** 的实验重点是“非精确求解能否减少内层成本，并通过较大乘子步长补偿误差”；
- **PADMC** 的实验重点是“凸组合近端中心参数是否改善 PADMM 的收敛表现”；
- **GrpADMM** 的实验重点是“黄金比例参数和强凸加速是否能在保持子问题易解的同时提升效率”。

推荐复现的公共模块

若后续要在 MATLAB 中复现实验，建议优先实现以下模块：

1. soft shrinkage 与向量组 shrinkage；
2. 相对函数值残差、可行性违反、PSNR/SNR 的统一计算；
3. CG/PCG 线性系统求解器与热启动接口；
4. 随机稀疏信号、相关高斯矩阵、Hadamard/DCT 矩阵、图像噪声生成器；
5. 参数扫描脚本，如 α、α_x、α_y、ψ、θ。